

《100天成为风控专家》

规则生成(3): 决策树(含实操)

出品: 东哥起飞

解锁风控课程



关注我的公众号





目录

一、决策树概念

1.1. 什么是决策树?

1.2. 决策树的生成过程

二、决策树算法

2.1. 算法分类

2.2. CART分类树—基尼系数

2.3. CART分类树—变量二分法

2.4. CART分类树—递归生成

2.5. CART回归树—预测方式

2.6. CART回归树—残差平方和

三、决策树生成规则

3.1. 决策树规则生成过程

3.2. 决策树规则注意事项

四、Python代码案例实操

4.1. Sklearn.tree的API方法

4.2. Sklearn.tree的API参数

4.3. Python代码实操



扫码加我微信






Python数据科学



扫码加我微信



一、决策树的概念




1.1. 什么是决策树?


决策树是一个if-then规则的集合，自顶向下按照某种度量标准不断地进行分裂，形状上如同一个树形的结构。

在树结构中（如下图），包括两种类型的节点：**分裂节点**、**末端节点**。分裂节点按照特征变量阈值的判断会向下分裂；而末端节点，也叫**叶子节点**是决策树的末梢终点，不会继续分裂。

分裂节点中又分**根节点**、**内部分裂点**，本质上是一样的，二者区别是根节点是决策树的起始节点，而内部分裂点在决策树内部。



扫码加我微信







1.2. 决策树的生成过程

那么决策树是如何生成的呢？

简单来说，决策树从根节点开始，在每个分裂节点均会按照“一定的度量标准”从特征变量池中筛选出最合适的变量以及变量对应的阈值，并不断地向下分裂，直到达到某种条件后停止分裂，最终输出叶子节点的数值或类别结果。


右侧示例就是决策树的一般生成过程，相当于通过特征变量的选择对样本的特征空间做非线性地划分，因此我们说决策树也是一种“**非线性模型**”。



特征空间的不相交子区域划分



扫码加我微信






Python数据科学



扫码加我微信



二、决策树算法






2.1. 算法分类

决策树有三种算法：ID3、C4.5、CART，其中ID3和C4.5用于分类，而CART既可以分类，也可以回归，并且是二叉树计算更快。下面我们以最常用的**CART算法**来举例说明，因为它也是后面模型篇各种集成树模型的基础，是比较重要的。



扫码加我微信





2.2. CART分类树—基尼系数

CART是 "Classification and Regression Trees" 的缩写，意思是 "分类回归树"。从它的名字上就不难理解了，CART算法是既可以用于分类的，也可以用于回归的。

基尼系数(Gini)

CART分类树算法使用“基尼系数(Gini)”选择特征，**基尼系数代表了模型的不纯度，基尼系数越小，不纯度越低，特征越好。**公式如下：

$$\begin{aligned} Gini(D) &= \sum_{k=1}^K p(x_k) * (1 - p(x_k)) \\ &= 1 - \sum_{k=1}^K p(x_k)^2 \end{aligned}$$

当n=2时




$$Gini(p) = 2p(1 - p)$$

这个公式中， $p(x_k)$ 表示分类 x_k 出现的概率， K 是分类的数目。比如在信贷风控中，我们的分类是好坏客户只有两类，基尼指数就等于 $2p(1-p)$ 。



扫码加我微信





2.2. CART分类树—基尼系数

对于给定的样本集合D，其基尼指数定义为：

$$\begin{aligned} Gini(D) &= \sum_{k=1}^K \frac{|C_k|}{|D|} \left(1 - \frac{|C_k|}{|D|}\right) \\ &= 1 - \sum_{k=1}^K \left(\frac{|C_k|}{|D|}\right)^2 \\ Gini(D|A) &= \sum_{i=1}^n \frac{|D_i|}{|D|} Gini(D_i) \end{aligned}$$


其中，k 代表类别， C_k 是D中属于第k类的样本子集。

当 CART 为二分类时，则在特征A的条件下，集合D的基尼指数定义为：

$$Gini(D|A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$



扫码加我微信





2.2. CART分类树—基尼系数

在信贷场景中我们想区分好坏客户，那么目标变量有两类：好客户和坏客户。我们举两个极端的情况说明。

1) 如果分裂后的节点中好坏客户各占50%，此时基尼指数为0.5，不纯度达到最大值，说明完全没有任何区分效果。

$$\begin{aligned} Gini(p) &= 2p(1-p) \\ &= 2 * \frac{1}{2} * (1 - \frac{1}{2}) \\ &= 0.5 \end{aligned}$$


2) 如果分裂后的节点中好客户占比100%，坏客户占比0%或者反过来，基尼系数为0，不纯度达到最小值，此时区分效果最强，完全是好或者坏客户，一边倒。

$$\begin{aligned} Gini(p) &= 2p(1-p) \\ &= 2 * 1 * (1 - 1) \\ &= 0 \end{aligned}$$

基尼指数反映了从数据集D中随机抽取两个样本，其类别标记不一致的概率。因此，Gini(D)越小，则数据集D的纯度越高。



扫码加我微信






2.3. CART分类树—变量二分法

对于连续型变量，假如变量a有连续值m个，从小到大排列。m个数值就有m-1个切分点，分别使用每个切分点把连续数值离散划分成两类，将分裂前数据集D按照划分点分为D1和D2两个子集，然后计算每个划分点下对应的基尼指数，选择值最小的一个作为最终的变量划分。




扫码加我微信



$$Gini_1(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

$$Gini_2(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$



$$Gini_{m-1}(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$



2.3. CART分类树—变量二分法

对于离散型变量，如果离散值多于两个，CART同样会不停的二分，将其中一个类别作为一类，其余所有类别归为一类。比如下图示例中，离散变量 a 有 m 个类别，split1中将 a_1 作为一类，剩余 a_2-a_m 归为一类，split2中将 a_2 作为一类，其余归为另一类，直到split($m-1$)划分都是同理。

与连续型变量处理方式一样，每次划分后分为D1和D2两个子集，然后计算每个划分点下对应的基尼指数，选择值最小的一个作为最终的变量划分。

Split 1:



Split 2:




...

...

Split $m-1$:



扫码加我微信





2.4. CART分类树—递归生成

输入：训练集D，基尼系数的阈值，切分的最少样本个数阈值

输出：分类树T


算法从根节点开始，用训练集递归建立CART分类树。

- ① 对于当前节点的数据集为D，如果样本个数小于阈值或没有特征，则返回决策子树，当前节点停止递归；
- ② 计算样本集D的基尼系数，如果基尼系数小于阈值，则返回决策子树，当前节点停止递归；
- ③ 计算当前节点现有各个特征的各个值的基尼指数；
- ④ 在计算出来的各个特征的各个值的基尼系数中，选择基尼系数最小的特征A及其对应的取值a作为最优特征和最优切分点。然后根据最优特征和最优切分点，将本节点的数据集划分成两部分D1和D2，同时生成当前节点的两个子节点，左节点的数据集为D1，右节点的数据集为D2；
- ⑤ 对左右的子节点递归调用1-4步，生成CART分类树；

对生成的CART分类树做预测时，假如测试集里的样本落到了某个叶子节点，而该节点里有多个训练样本。则该测试样本的类别为这个叶子节点里概率最大的类别。



扫码加我微信





2.5. CART回归树—预测方式

与分类树不同，回归树的预测变量是连续值，比如预测一个人的年龄，又或者预测季度的销售额等等。另外，回归树在**选择特征的度量标准**和**决策树建立后预测的方式**上也存在不同。

① 预测方式

一个回归树对应着输入特征空间的一个划分，以及在划分单元上的输出值。现在假设数据集已被划分， $R_1, R_2, \dots, R_m$ 共m的子集，回归树要求每个划分 R_m 中都对应一个固定的输出值 c_m 。

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

这个 c_m 值其实就是每个子集中所有样本的目标变量y的平均值，并以此 c_m 作为该子集的预测值。所有分支节点都是如此，叶子节点也不例外。因此，可以知道回归树的预测方式是：**将叶子节点中样本的y均值作为回归的预测值。而分类树的预测方式则是：叶子节点中概率最大的类别作为当前节点的预测类别。**



扫码加我微信





2.6. CART回归树—残差平方和

② 选择特征的度量标准

CART回归树对于变量类型的处理与分类树一样，连续值与离散值分开对待，并只能生成二叉树。但是CART回归树对于选择变量的度量标准则完全不同。

分类树的特征选择标准使用基尼指数，而回归树则使用**残差平方和(RSS)**，通过**最小化残差平方和作为判断标准**，公式如下：

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

y_i : 样本目标变量的真实值;
 R_1 & R_2 : 被划分的两个子集;
 c_1 & c_2 : R_1 & R_2 子集的样本均值;
 j : 当前的样本特征;
 s : 划分点;

上面公式的含义是：计算所有的“变量和切分点”组合的残差平方和，找到一组(变量 j ，切分点 s)，以分别最小化左子树和右子树的残差平方和，并在此基础上再次最小化二者之和。

其实，回归树也有分类的思想。所谓“物以类聚”，相同类之间的目标变量值才会更接近，方差值也就会更小。



扫码加我微信






Python数据科学



扫码加我微信




三、决策树生成规则





3.1. 决策树生成规则过程


以信贷风控场景为例，假如样本的整体坏账率badrate为6%，有征信、公积金、房屋资产等维度的数据，现在基于以上所有变量和目标变量生成一个决策树，树深为2，具体如下。



规则制定：（过去3个月查询机构数>6）且（是否有公积金=否），触发则拒绝，反之通过。



扫码加我微信





3.2. 决策树规则注意事项

① 规则的复杂度

随着树深度不断增加，对客群的划分更加细致精准，但也容易出现两个问题，一是容易过拟合，在训练样本上效果好，但在时间外OOT样本上效果差；二是树深度过深，会导致生成的规则过于复杂，不利于上线后的监控和运营维护。比如，当规则出现异常时，需要定位变量的原因，对于一条包含很多个变量的规则，排查难度会增加。**在信贷风控中，一条规则包含的变量数不超过3个。**

② 规则评估指标

与单变量、交叉表的评估指标相同，综合考虑精准率、召回率、命中率等指标，以此评估规则的可用性。

③ 规则可解释性

通过决策树生成的规则也需要满足业务的可解释性。



扫码加我微信






Python数据科学



扫码加我微信



四、Python代码案例实操





4.1. Sklearn.tree的API方法

Sklearn中有两个决策树API方法，分别是：

- ① **tree.DecisionTreeClassifier**: CART分类树
- ② **tree.DecisionTreeRegressor**: CART回归树

要注意的是，Sklearn没有对ID3和C4.5算法的实现，就只有CART算法，并且是调优过的。下面是官方文档的说明。

<https://scikit-learn.org/stable/modules/tree.html#tree-algorithms-id3-c4-5-c5-0-and-cart>

1.10.6. Tree algorithms: ID3, C4.5, C5.0 and CART


What are all the various decision tree algorithms and how do they differ from each other? Which one is implemented in scikit-learn?

► Various decision tree algorithms

scikit-learn uses an optimized version of the CART algorithm; however, the scikit-learn implementation does not support categorical variables for now.



扫码加我微信






4.2. Sklearn.tree的API参数

DecisionTreeClassifier参数如下:

1. **Criterion:** 特征选择的度量标准, 可以选择 "gini" 或 "entropy". 默认情况下使用 "gini", 是 CART算法的标准。
2. **Splitter:** 用于指定节点分裂的方式, 可以选择 "best" 或 "random". 默认情况下是 "best", 即在所有可能的划分点中选择最优的划分点. "random" 则是随机选择局部最优的划分点。
3. **Max_Depth:** 用于限制决策树的深度, 如果没有设置, 则表示没有限制. 这是一个重要的参数, 因为它可以帮助防止决策树变得过于复杂, 从而避免过拟合。
4. **Min_Samples_Split:** 指定节点分裂所需的最低样本数. 如果某个节点的样本数量少于这个值, 则不会进行分裂。
5. **Min_Samples_Leaf:** 指定叶子节点所需的最低样本数. 如果某个叶子节点的样本数量少于这个值, 会与它的兄弟节点合并。



扫码加我微信





4.2. Sklearn.tree的API参数

- 6. **Max_Features:** 用于控制每次寻找最优划分时考虑的特征数量的上限。这有助于减少决策树的复杂性，同时保持模型的准确性。
- 7. **Random_State:** 随机种子，用于确保每次训练的结果一致性。如果没有设置随机种子，则每次训练可能会得到不同的结果。
- 8. **Class_Weight:** 用于指定不同类别的权重，以平衡数据集中的类别不平衡问题。
- 9. **Min_ Impurity_Decrease:** 指定分割后的信息增益阈值，如果小于这个值就不继续分裂。
- 10. **CCP_Alpha:** 剪枝复杂度惩罚项系数，用于指导剪枝过程。



扫码加我微信

