

# 《100天风控专家》

## 置换策略的D类调优(1): 理论介绍

出品: 东哥起飞

解锁风控课程



关注我的公众号





# 1. 什么是置换策略?

## 1) 概念理解

置换策略, 又叫 “swap-in-swap-out” 置入置出策略, 是通过设计一个全新的策略来替代已有旧策略的优化方法。它与规则阈值收紧、策略新增不同, 不是在已有策略上做调整、新增或者收紧, 而是完全替换。该优化方法在策略的优化迭代中频繁使用, 是策略分析师必备的技能之一。

## 2) 业务场景

置换策略既可以应用在A类调优, 也可以应用在D类调优场景中。通过置入置出, 可以实现 **“保持通过率不变, 降低逾期率”** 或者 **“保持逾期率不变, 提高通过率”** 的目的。

## 3) 置换对象

置换对象可以是以规则为主的策略, 也可以是以模型为主的策略。例如, 模型策略的置换, 近期通过监控报表发现, 线上主模型KS指标持续下滑, 为此模型团队迭代了一版新模型, 交付给了策略团队。策略团队需要做一件事情: **从业务角度, 对新/旧模型进行离线对比测试, 此时就需要用到置换策略, 即对模型的置换分析。**



扫码进专属群






## 2. 什么是置入置出?

所谓“置换”，包括置入和置出两部分，什么是置入置出呢？

举例说明下。右侧是模型迭代前后的置换分析示例，展示了新旧模型在通过和拒绝状态下样本的浓度，其中绿色样本代表好客户，红色样本代表坏客户。

- ✓ **置入**：旧模型(策略)拒绝的，而新模型通过的
- ✓ **置出**：旧模型(策略)通过的，而新模型拒绝的

在这个示例中，置换就是新旧模型在决策上的“差异部分”，可以看到，置入部分的坏客户浓度要低于置出部分。



扫码进专属群





## 3. 分析步骤

分析步骤大致如下：

**1) 调优需求：**政策指导、市场变化导致资产质量变差、监控报表发现逾期率升高等。

**2) 提取样本：**挑选合适的历史样本（代表性、充分性、数据可回溯性、时效性），并且回溯数据（具体可参考模型篇“样本设计”内容）

**3) 策略开发：**开发设计出新模型(策略)

**4) 决策分析：**分别执行新、旧模型(策略)的决策判断，生成决策结果

**5) 效果测试：**对新旧模型(策略)的决策结果（“通过”和“拒绝”两个状态）进行决策矩阵分析。如果是D类调优，则将新旧模型(策略)的通过率保持相同，比较逾期率的大小；如果是A类调优，则将新旧模型(策略)的逾期率保持相同，比较通过率的大小。

**6) 策略上线：**决策引擎配置策略后，进行灰度测试或者AB测试观察效果，想确认后再正式上线



扫码进专属群



## 4. 决策结果交叉分析

以下是新旧模型(策略)的决策结果交叉分析，以D类调优场景为例，我们想实现“**通过率不变或升高的情况下，降低逾期率**”。分析步骤：1) 首先开发出新模型(策略)；2) 计算新旧模型(策略)决策结果；3) 透视表交叉统计，统计出区间坏客户数量、总客户数量；4) 基于步骤3结果（左侧上下两图）计算出区间坏账率bad rate、区间客户的占比，分别反映逾期率和通过率（e.g. 区间坏账率(bad rate)  $4.51\% = 1641/36417$ ；区间客户占比  $72.83\% = 36417/50000$ ）；5) 比较新旧模型的通过率和逾期率

| 区间坏客户数量 | 新模型  |      |      |
|---------|------|------|------|
| 旧模型     | 通过   | 拒绝   | All  |
| 通过      | 1641 | 1508 | 3149 |
| 拒绝      | 0    | 0    | NaN  |
| All     | 1641 | 1508 | 3149 |

| 区间总客户数量 | 新模型   |      |       |
|---------|-------|------|-------|
| 旧模型     | 通过    | 拒绝   | All   |
| 通过      | 36417 | 3990 | 40407 |
| 拒绝      | 6729  | 2864 | 9593  |
| All     | 43146 | 6854 | 50000 |

| 区间坏账率(badrate) | 新模型   |        |       |
|----------------|-------|--------|-------|
| 旧模型            | 通过    | 拒绝     | All   |
| 通过             | 4.51% | 37.79% | 7.79% |
| 拒绝             | 0.00% | 0.00%  | 0.00% |
| All            | 3.80% | 22.00% | 6.30% |

| 区间客户占比 | 新模型    |        |         |
|--------|--------|--------|---------|
| 旧模型    | 通过     | 拒绝     | All     |
| 通过     | 72.83% | 7.98%  | 80.81%  |
| 拒绝     | 13.46% | 5.73%  | 19.19%  |
| All    | 86.29% | 13.71% | 100.00% |



扫码进专属群





## 5. 新旧效果对比

### 如何对比新旧模型(策略)的效果呢?

在D类调优场景中，完成决策结果交叉分析后，我们先看通过率的对比情况，目的是保持新模型(策略)的通过率与旧模型(策略)相同。如果说通过率相差太多则需要重新调整新模型(策略)的阈值，再来重新做透视交叉统计。

然后基于此条件下，再去对比二者的坏账率，即新模型(策略)置入和置出的部分。如果说新模型置入部分的坏账率低于置出部分的坏账率，则说明新模型(策略)是更优的，否则就是不如原模型(策略)。

| 区间坏客户数量 | 新模型  |      |      |
|---------|------|------|------|
| 旧模型     | 通过   | 拒绝   | All  |
| 通过      | 1641 | 1508 | 3149 |
| 拒绝      | 0    | 0    | NaN  |
| All     | 1641 | 1508 | 3149 |

| 区间总客户数量 | 新模型   |      |       |
|---------|-------|------|-------|
| 旧模型     | 通过    | 拒绝   | All   |
| 通过      | 36417 | 3990 | 40407 |
| 拒绝      | 6729  | 2864 | 9593  |
| All     | 43146 | 6854 | 50000 |

| 区间坏账率(badrate) | 新模型   |        |       |
|----------------|-------|--------|-------|
| 旧模型            | 通过    | 拒绝     | All   |
| 通过             | 4.51% | 37.79% | 7.79% |
| 拒绝             | ?     | 0.00%  | 0.00% |
| All            | 3.80% | 22.00% | 6.30% |

| 区间客户占比 | 新模型    |        |         |
|--------|--------|--------|---------|
| 旧模型    | 通过     | 拒绝     | All     |
| 通过     | 72.83% | 7.98%  | 80.81%  |
| 拒绝     | 13.46% | 5.73%  | 19.19%  |
| All    | 86.29% | 13.71% | 100.00% |



扫码进专属群





## 6. 置入样本坏账率预测—离线预估

由于旧模型(策略)拒绝样本没有贷后表现，为比较新模型(策略)置入和置出部分的坏账率大小，需要对置入部分的坏账率进行预估。在离线分析时如何进行预估呢？这里提供一种测算方法。

核心思想是：**一般来说新开发的模型要优于旧模型，所以我们先假设新模型效果是更好的。然后基于新模型在通过样本上的风险分层，来衡量置入部分的贷后表现。**

具体操作为：

- 1) 对新模型在通过样本上进行风险分层，统计区间坏账率；
- 2) 将该分层在旧模型拒绝样本上执行，并统计数量的分布；

3) 此时通过1/2步骤得到的分层是一样的，但分布有差异（由于新旧模型不同），用步骤2分层下的样本数量乘以新模型在通过样本上的区间坏账率，即得到了拒绝样本分层下的坏客户数量；

- 4) 最后，根据新模型(策略)的cutoff(需与计算决策结果时保持一致)来计算置入部分的坏账率。

该方法的缺陷是：**由于新模型是在通过样本上开发的，而现在用来预测拒绝样本的贷后表现，在客群上是存在一定偏差的，因此对于置入部分的坏账率测算存在低估的可能。**



扫码进专属群



## 6. 置入样本坏账率预测—离线预估

### 1) 对新模型在通过样本上进行风险分层，统计区间坏账率

| no. | variable   | bin        | count | count_distr | good  | bad  | badprob |
|-----|------------|------------|-------|-------------|-------|------|---------|
| 0   | risk_score | [-inf,2.0) | 10085 | 24.96%      | 10053 | 32   | 0.32%   |
| 1   | risk_score | [2.0,3.0)  | 6652  | 16.46%      | 6558  | 94   | 1.41%   |
| 2   | risk_score | [3.0,4.0)  | 7103  | 17.58%      | 6828  | 275  | 3.87%   |
| 3   | risk_score | [4.0,5.0)  | 6457  | 15.98%      | 6041  | 416  | 6.44%   |
| 4   | risk_score | [5.0,6.0)  | 6120  | 15.15%      | 5296  | 824  | 13.46%  |
| 5   | risk_score | [6.0,inf)  | 3990  | 9.87%       | 2482  | 1508 | 37.79%  |

### 2) 统计旧模型拒绝样本的数量分布

| no. | variable   | risk_score | bins_cnt |
|-----|------------|------------|----------|
| 0   | card_level | [-inf,2.0) | 866      |
| 1   | card_level | [2.0,3.0)  | 868      |
| 2   | card_level | [3.0,4.0)  | 1317     |
| 3   | card_level | [4.0,5.0)  | 1619     |
| 4   | card_level | [5.0,6.0)  | 2059     |
| 5   | card_level | [6.0,inf)  | 2864     |

### 3) 计算拒绝样本分层下的坏客户数量

|   | variable   | bin        | count | count_distr | good  | bad  | badprob | bins_cnt | jjbad_cnt |
|---|------------|------------|-------|-------------|-------|------|---------|----------|-----------|
| 0 | risk_score | [-inf,2.0) | 10085 | 24.96%      | 10053 | 32   | 0.32%   | 866      | 3         |
| 1 | risk_score | [2.0,3.0)  | 6652  | 16.46%      | 6558  | 94   | 1.41%   | 868      | 12        |
| 2 | risk_score | [3.0,4.0)  | 7103  | 17.58%      | 6828  | 275  | 3.87%   | 1317     | 51        |
| 3 | risk_score | [4.0,5.0)  | 6457  | 15.98%      | 6041  | 416  | 6.44%   | 1619     | 104       |
| 4 | risk_score | [5.0,6.0)  | 6120  | 15.15%      | 5296  | 824  | 13.46%  | 2059     | 277       |
| 5 | risk_score | [6.0,inf)  | 3990  | 9.87%       | 2482  | 1508 | 37.79%  | 2864     | 1082      |

拒绝样本分布及坏客户

4) 对新模型置入部分  
计算坏账率为6.65%



扫码进专属群





## 6. 置入样本坏账率预测—离线预估

经过前面计算后，获取了置入部分的坏账率预估，结果如下。

| 区间坏客户数量 | 新模型  |      |      |
|---------|------|------|------|
| 旧模型     | 通过   | 拒绝   | All  |
| 通过      | 1641 | 1508 | 3149 |
| 拒绝      | 448  | 0    | NaN  |
| All     | 2089 | 1508 | 3149 |

| 区间总客户数量 | 新模型   |      |       |
|---------|-------|------|-------|
| 旧模型     | 通过    | 拒绝   | All   |
| 通过      | 36417 | 3990 | 40407 |
| 拒绝      | 6729  | 2864 | 9593  |
| All     | 43146 | 6854 | 50000 |

| 区间坏账率(badrate) | 新模型   |        |       |
|----------------|-------|--------|-------|
| 旧模型            | 通过    | 拒绝     | All   |
| 通过             | 4.51% | 37.79% | 7.79% |
| 拒绝             | 6.65% | 0.00%  | 0.00% |
| All            | 4.84% | 22.00% | 6.30% |

| 区间客户占比 | 新模型    |        |         |
|--------|--------|--------|---------|
| 旧模型    | 通过     | 拒绝     | All     |
| 通过     | 72.83% | 7.98%  | 80.81%  |
| 拒绝     | 13.46% | 5.73%  | 19.19%  |
| All    | 86.29% | 13.71% | 100.00% |

### ✓ 通过率对比

- ◆ 新模型通过率为86.29%，旧模型通过率为80.81%；

### ✓ 逾期率对比

- ◆ 新模型置入部分的坏账率为6.65%，置出部分的坏账率为37.79%；新模型通过部分的坏账率为4.84%，旧模型通过部分的坏账率为7.79%。



扫码进专属群





## 6. 置入样本坏账率预测—线上测试

① 如果历史有做过“AB测试”或“灰度测试”，可以使用测试期间样本的贷后表现预估

✓ **AB测试**：如果旧模型(策略)上线时有进行过AB测试，比如A组（对照组）只打分不生效，B组（实验组）打分并生效。由于B组中低于cutoff的客户将会被策略拒绝，那么就可以从A组中低于cutoff的放贷客群的badrate作为B组的近似估计。

✓ **灰度测试**：如果旧模型(策略)上线前进行过灰度测试，由于灰度期间只打分不生效，可以用来预估旧模型(策略)拒绝样本的bad rate。

② 使用“随机测试”直接获取拒绝样本的贷后表现


✓ **分流比例**：比例不宜过高（结合样本量考虑，一般控制在2%以内），以避免损失严重，同时样本量需满足最小统计要求，否则没有统计意义。

✓ **豁免**：随机测试样本，只打分不生效，且会“豁免”直接通过审批，不会被决策流后面策略拒绝，否则获取的贷后表现可能失真。

✓ **优缺点**：优点是获取信息最为准确，无需预测，缺点是需要一定的观察周期，并且会产生一定的坏账损失。



扫码进专属群



# 谢谢

出品人：东哥起飞

解锁风控课程



关注我的公众号



Python数据科学



扫码进专属群

