

《100天风控专家》

样本划分和抽样

出品：东哥起飞

解锁风控课程



关注我的公众号





加V进专属交流群



1. 样本划分分类

样本划分是指将建模的样本进行一定的拆分，完整情况可划分为以下几种：**训练集、验证集、测试集、和时间外测试集（oot）。**

样本划分

01 训练集(train set)

用于训练模型，通过算法拟合数据构建模型。

02 验证集 (valid set)

主要用于对训练模型的超参数进行调整。一般使用于超参数较多的算法，如XGBoost，而对于逻辑回归算法来说一般不使用验证集。

03 测试集 (test set)

主要用于验证调完参训练后的模型是否会出现过拟合或者欠拟合的情况，该测试集不考虑时间因素，与训练集、验证集为同一个时间范围。

04 时间外测试集 (out of time test set)

主要用于验证跨周期的时间外样本上的模型表现，评估模型效果是否会随着时间变化而变差，考虑了时间对于模型效果的影响。




加V进专属交流群



2. 样本划分比例

训练集、验证集、测试集是同一时间范围的样本，并按照一定的比例进行拆分，比例一般是6:2:2。**对于评分卡使用逻辑回归算法的模型来说，通常不需要验证集，则训练集和测试集的比例，常见可设为7:3或8:2。**需要尽量保证训练集的样本数量充足，如果不充足该比例需要灵活调整。

和时间外测试集（oot）一般靠近在离当前时点更近的位置，时间上一般预留1-3个月的样本量作为样本外的模型效果测试。当然也有部分认为应保证训练集的样本的时效性，将时间外样本放置在训练集之前的。





加V进专属交流群



3. 样本抽样

1) 什么是样本抽样?

样本抽样就是对样本中好或者坏客户按照一定比例进行抽取, 以达到好坏样本均衡的目的。

注: 经过模型设计排除规则后的好坏样本(正负样本), 并非的最终直接训练的样本, 还需对好坏样本的比例进行均衡调整。

2) 为什么做样本抽样?

- ① 虽然做模型要求样本量, 但也并非越大越好, 样本量足够且有代表性即可, 一般超过5万时模型效果不会再随着样本量的增加而有显著变化。**过多的样本量会让模型训练过程非常耗时, 增加训练负担。**
- ② 好坏比例需要均衡。一般坏客户的量相对少, **如果好客户占比非常高、坏账率特别低的情况下, 坏客户被稀释导致模型很难学习到坏客户的特征。**



加V进专属交流群



3. 样本抽样


3) 如何做样本抽样?

首先要保证好坏样本的绝对值数量足够多，其次通过抽样达到想要的好坏比。

一般情况坏样本数量是有限的，此时会考虑使用全部坏样本，通过好样本抽样来控制最终好坏比例。比如，真实情况下坏账率仅为2%，现在想要提升样本坏账率到10%，那么根据坏样本数量和10%就可以计算出需要多少数量的好样本配比，进而就可以得到好样本的抽样比例了。**这种情况的核心思想就是，以有限的坏样本为主，好样本通过抽样配合达到目标好坏比。**

4) 样本划分是如何抽样的?

建议使用“**分层抽样**”的方法。分层抽样就是分层的随机抽样，可以保证各抽样组与总体有相同的比例。比如，总样本好坏比例为9:1，如按好坏客户进行分层抽样（即按照好和坏样本单独随机抽样），就可以保证训练样本、测试样本上的好坏比例相同（即与总样本好坏比相同），进而避免在模型效果评估时因分布差异而导致的偏差。该方法在样本不均衡时尤其建议使用，否则可能会出现模型在训练集、测试集上的结果差异较大，导致模型不稳定。



3. 样本划分抽样代码示例

在Python中我们通过sklearn的train_test_split函数设置stratify参数实现分层抽样。

```
from sklearn.model_selection import train_test_split

train_set, test_set = train_test_split(df, test_size=0.4, stratify=df['label'], random_state=42)
print (train_set)
```

对stratify参数指定要分层的字段，此例中为label，即目标变量Y。得到训练集train_set和测试集test_set的好坏比是与统计样本df一致的。

5) 样本抽样注意事项

抽样会改变原始样本的分布，比如真实样本的坏账率为2%，但建模样本坏账率可能为10%。**该分布的变化并不影响建模的过程，但是在建模后一般会进行“样本权重的还原”，这样在模型效果评估时就可以与真实样本坏账率进行比较，而不是只看模型的排序性了。**



加V进专属交流群



谢谢

出品人：东哥起飞

解锁风控课程



关注我的公众号



公众号: Python数据科学



加V进专属交流群

