

《100天风控专家》

WOE和IV计算和应用

出品：东哥起飞

解锁风控课程



关注我的公众号



公众号: Python数据科学



加V进专属交流群



一、WOE的概念、理解、计算



加V进专属交流群



1.1. 什么是WOE?

1) WOE公式

WOE (Weight of Evidence) 证据权重, 是变量的一种编码方法, 属于**有监督学习**的编码类型。

WOE编码计算需要两个前提条件: 1) 样本需匹配Y标签, 即确定好客户还是坏客户; 2) 需提前对变量进行分箱操作, 按照适合的统计数量进行划分。具体公式如下:

$$\begin{aligned} WOE_i &= \ln\left(\frac{Bad_i}{Bad_T} / \frac{Good_i}{Good_T}\right) \\ &= \ln\left(\frac{Bad_i}{Bad_T}\right) - \ln\left(\frac{Good_i}{Good_T}\right) \longrightarrow \text{边际好/坏客户占比之差} \\ &= \ln\left(\frac{Bad_i}{Good_i}\right) - \ln\left(\frac{Bad_T}{Good_T}\right) \longrightarrow \text{分箱坏好比与总体坏好比之差} \end{aligned}$$

公式符号含义:

- Bad_i: 每个分箱内的坏客户数量
- Bad_T: 总的坏客户数量, 即所有分箱坏客户数量求和
- Good_i: 每个分箱内的好客户数量
- Good_T: 总的好客户数量, 即所有分箱好客户数量求和



加V进专属交流群



1.2. WOE计算示例

2) WOE计算过程

以下为某连续型变量分箱后进行的WOE编码计算过程。

① 分箱

				② 边际坏占比	③ 边际好占比	④ 计算WOE	
bins	total	good	bad	bad_rate	margin_bad_rate	margin_good_rate	WOE
1	200	195	5	2.5%	2.33%	14.08%	-1.80
2	200	190	10	5.0%	4.65%	13.72%	-1.08
3	200	185	15	7.5%	6.98%	13.36%	-0.65
4	200	180	20	10.0%	9.30%	13.00%	-0.33
5	200	175	25	12.5%	11.63%	12.64%	-0.08
6	200	165	35	17.5%	16.28%	11.91%	0.31
7	200	155	45	22.5%	20.93%	11.19%	0.63
8	200	140	60	30.0%	27.91%	10.11%	1.02
total	1600	1385	215	13.4%	100.00%	100.00%	

以第一箱(bins=1)为例:

margin_bad_rate(边际坏占比) = 5/215=2.33%

margin_good_rate(边际好占比) = 195/1385=14.08%

WOE = ln(margin_bad_rate) – ln(margin_good_rate) = ln(2.33%)-ln(14.08%)=-1.80



加V进专属交流群



1.3. WOE的含义

3) WOE的含义

通过下面示例观察，每个分箱都有一个对应的WOE值，其值有如下含义：

- **WOE越大，bad_rate越高。**
- **WOE值描述了样本是否属于坏客户的方向和大小。**当WOE为正时，说明客户是坏客户的方向，当WOE为负时，说明客户不是坏客户的方向。而值的大小则说明了在方向上的影响程度，值越大越倾向坏客户。
- **WOE的取值范围是全体实数，经验上取值在(-3,3)之间。**

bins	total	good	bad	bad_rate	margin_bad_rate	margin_good_rate	WOE
1	200	195	5	2.5%	2.33%	14.08%	-1.80
2	200	190	10	5.0%	4.65%	13.72%	-1.08
3	200	185	15	7.5%	6.98%	13.36%	-0.65
4	200	180	20	10.0%	9.30%	13.00%	-0.33
5	200	175	25	12.5%	11.63%	12.64%	-0.08
6	200	165	35	17.5%	16.28%	11.91%	0.31
7	200	155	45	22.5%	20.93%	11.19%	0.63
8	200	140	60	30.0%	27.91%	10.11%	1.02
total	1600	1385	215	13.4%	100.00%	100.00%	

1.4. WOE公式的进一步理解

4) WOE的公式理解

- ① 一般公式含义: 表示每个分箱里的坏好比(Odds)相对于总体的坏好比之间的差异性

第i个分箱的WOE = $\ln(\text{第i个分箱的坏人数} / \text{第i个分箱的好人数}) - \ln(\text{总坏人数} / \text{总好人数})$

$$WOE_i = \ln\left(\frac{Bad_i}{Bad_T} / \frac{Good_i}{Good_T}\right) = \ln\left(\frac{Bad_i}{Good_i}\right) - \ln\left(\frac{Bad_T}{Good_T}\right)$$

- ② 贝叶斯角度含义: 用以衡量对先验认识修正的增量

$$P(A|B) = P(B|A) * \frac{P(A)}{P(B)}$$



修正增量

$$\begin{aligned} \ln\left(\frac{p(Y = Bad|X)}{p(Y = Good|X)}\right) &= \ln\left(\frac{p(X|Y = Bad)}{p(X|Y = Good)}\right) + \ln\left(\frac{p(Y = Bad)}{p(Y = Good)}\right) \\ &\Rightarrow \ln\left(\frac{Bad}{Good}\right) = WOE + \ln\left(\frac{Bad_T}{Good_T}\right) \\ &\Rightarrow WOE = \ln\left(\frac{Bad}{Good}\right) - \ln\left(\frac{Bad_T}{Good_T}\right) \end{aligned}$$

后验 ← → 先验

参考链接: <https://zhuanlan.zhihu.com/p/80134853>



加V进专属交流群



1.5. 为什么要做WOE?

5) WOE的优点

对于使用逻辑回归算法的评分卡模型来说, 为什么要做WOE编码的转换呢?

① 增强泛化能力

- 将取值较多的连续型变量转换成固定的分箱WOE值 (一般不超过8个), 一定程度上可以增加泛化能力

② 可解释性

- WOE值的正负关系可以代表离散区间样本的好坏程度, 有较好的解释意义
- WOE值的分布可以体现出数据分布的单调性趋势, 便于特征变量的筛选

③ 变量稳定性

- 分箱可以对变量取值起到平滑处理作用 (比如说年龄异常值为300, 分在年龄>60这箱里, 排除异常值的影响; 再比如对缺失值可以单独分一箱处理), 提高了变量的鲁棒性
- WOE编码对原数据有标准化的意义, 将所有变量转换为统一的量纲下, 利于逻辑回归线性模型的拟合

④ IV值计算基础

- WOE值转换后更便于IV值的推导与分析



加V进专属交流群



1.6. WOE的注意事项

6) WOE的注意事项

① 最小数量

- 为确保有统计意义, 每箱样本数量不能过少, **占比一般要求5%以上**。

② 极值处理

- 分箱内可能会出现只有坏客户或只有好客户的情况, 当0作为分母计算时, 可能会导致计算报错。

③ 缺失值处理

- 在分箱时, 通常将缺失值单独分为一箱。因为缺失值和非缺失值是无法比较的, 因此看变量区间坏账率单调性时, 可将缺失值一箱忽略不计, 只看非缺失分箱的单调性。

④ 分箱数量

- 分箱数量不易过多, 一般来说不要超过8箱。因为IV是建立在WOE基础上计算出来的, 箱数越多, 会导致IV值越大, 对变量筛选不公平。

⑤ 分箱合并

- 如果相邻分箱的WOE值相同, 则将其合并为一个分箱



加V进专属交流群



100天风控专家

100天风控专家

公众号: Python数据科学



加V进专属交流群



100天风控专家

二、IV的概念、理解、评估标准

100天风控专家

100天风控专家

100天风控专家

100天风控专家



2.1. 什么是IV?

1) IV公式

IV (Information Value) 是用来衡量变量预测能力的, 它在**WOE基础上做了一定的加权**, 具体公式如下:

$$IV_i = \left(\frac{Bad_i}{Bad_T} - \frac{Good_i}{Good_T} \right) * WOE_i$$

$$= \left(\frac{Bad_i}{Bad_T} - \frac{Good_i}{Good_T} \right) * \ln \left(\frac{Bad_i}{Bad_T} \frac{Good_T}{Good_i} \right)$$

$$IV = \sum_{i=1}^n IV_i$$

公式符号含义:

- Bad_i: 每个分箱内的坏客户数量
- Bad_T: 总的坏客户数量, 即所有分箱坏客户数量求和
- Good_i: 每个分箱内的好客户数量
- Good_T: 总的好客户数量, 即所有分箱好客户数量求和
- WOE_i: 每个分箱的WOE值
- IV_i: 每个分箱的IV值
- IV: 变量的IV值, 即所有分箱IV值之和



加V进专属交流群





加V进专属交流群



2.2. IV计算示例

2) IV计算过程

bins	total	good	bad	bad_rate	margin_bad_rate	margin_good_rate	WOE	IV
1	200	195	5	2.5%	2.33%	14.08%	-1.80	0.21
2	200	190	10	5.0%	4.65%	13.72%	-1.08	0.10
3	200	185	15	7.5%	6.98%	13.36%	-0.65	0.04
4	200	180	20	10.0%	9.30%	13.00%	-0.33	0.01
5	200	175	25	12.5%	11.63%	12.64%	-0.08	0.00
6	200	165	35	17.5%	16.28%	11.91%	0.31	0.01
7	200	155	45	22.5%	20.93%	11.19%	0.63	0.06
8	200	140	60	30.0%	27.91%	10.11%	1.02	0.18
total	1600	1385	215	13.4%	100.00%	100.00%		0.62

以第一箱(bins=1)为例:

$\text{margin_bad_rate}(\text{边际坏占比}) = 5/215=2.33\%$

$\text{margin_good_rate}(\text{边际好占比}) = 195/1385=14.08\%$

$\text{WOE} = \ln(\text{margin_bad_rate}) - \ln(\text{margin_good_rate}) = \ln(2.33\%) - \ln(14.08\%) = -1.80$

$\text{IV} = (\text{margin_bad_rate} - \text{margin_good_rate}) * \text{WOE} = (2.33\% - 14.08\%) * (-1.80) = 0.21$

$\text{变量总IV值} = 0.21 + 0.10 + 0.04 + \dots + 0.06 + 0.18 = 0.62$



加V进专属交流群



2.3. IV和WOE的关系

3) IV和WOE的关系

WOE表示每个分箱里的坏好比(Odds)相对于总体的坏好比之间的差异性，但未考虑分组中的样本占整体样本比例的因素，而IV则增加了样本权重的因素。如果一个分组的WOE值很高，但是样本数占整体样本数很低，虽然组内坏好比差异大，但并不能真实反映变量整体的预测能力。

case1

bins	total	good	bad	bad_rate	margin_bad_rate	margin_good_rate	WOE	IV
1	200	195	5	2.5%	2.33%	14.08%	-1.80	0.21
2	200	190	10	5.0%	4.65%	13.72%	-1.08	0.10
3	200	185	15	7.5%	6.98%	13.36%	-0.65	0.04
4	200	180	20	10.0%	9.30%	13.00%	-0.33	0.01
5	200	175	25	12.5%	11.63%	12.64%	-0.08	0.00
6	200	165	35	17.5%	16.28%	11.91%	0.31	0.01
7	200	155	45	22.5%	20.93%	11.19%	0.63	0.06
8	200	140	60	30.0%	27.91%	10.11%	1.02	0.18
total	1600	1385	215	13.4%	100.00%	100.00%		0.62

背景：case2在case1基础上做了一些改动，样本数量由200变为50，保持bad_rate不变，对比WOE和IV的变化。

case2

bins	total	good	bad	bad_rate	margin_bad_rate	margin_good_rate	WOE	IV
1	200	195	5	2.5%	2.94%	15.23%	1.64	0.20
2	200	190	10	5.0%	5.88%	14.84%	0.93	0.08
3	200	185	15	7.5%	8.82%	14.45%	0.49	0.03
4	200	180	20	10.0%	11.76%	14.06%	0.18	0.00
5	200	175	25	12.5%	14.71%	13.67%	0.07	0.00
6	200	165	35	17.5%	20.59%	12.89%	0.47	0.04
7	200	155	45	22.5%	26.47%	12.11%	0.78	0.11
8	50	35	15	30.0%	8.82%	2.73%	1.17	0.07
total	1450	1280	170	11.7%	100.00%	100.00%		0.54

观察结果：case2第8箱的WOE为1.17，高于case1的1.02，但是IV值却只有0.07，远低于case1的0.18



加V进专属交流群



2.4. IV的应用

4) IV的应用

在评分卡建模过程中，IV值通常用来筛选变量。IV值越大，代表好坏区分能力越强。

其评价标准可参考以下：

IV值区间	区分效果
≤ 0.02	微弱
$(0.02, 0.1]$	弱
$(0.1, 0.3]$	中
$(0.3, 0.5]$	强
> 0.5	超强

- ① 不同风控场景下的变量预测能力是各有差异的。例如，贷中的行为变量（额度使用率、逾期行为等）和预测目标的关联性更强，所以其IV值一般会非常高，和贷前授信审批时的多头、负债等变量相比效果更强。因此，在做ABC卡时，对于变量IV值的筛选标准也需要差异化对待。
- ② 建模筛选变量需要考虑变量IV的相对值。例如，在一些建模环境下（比如某维度数据的子模型）缺少有效区分的变量，可能所有变量IV值均小于0.1，此时需要看IV相对值选择更优的。

2.5. IV的注意事项

5) IV的注意事项

① IV是非负值

② 同一变量的分组越多, IV值越大

- 分组过多会使每个分组数量变少, 导致分布不稳定; 同时分组多可能会打破变量的单调性。因此基于IV值筛选变量时, 不能为了提高IV值一味地将分箱的数目提高, 也要兼顾变量的业务含义和分布的稳定性。

③ IV值异常高, 需要排除是否有“数据穿越”

- IV值代表变量和预测目标之间的关系, 如果IV值高的离谱, 比如贷前变量 $IV > 0.5$ 或者贷中 $IV > 1$, 则需要检查是否存在数据穿越的问题。因为数据穿越是建模的作弊行为, 会导致过拟合, 线上效果变差不达预期。

④ 调整分箱时, 注意IV值陷阱

- 如果某一分箱下全部为坏客户数, 则权重会变为100%, 导致该分箱的IV值异常高, 进而导致变量整体IV值也升高。此时的高IV值并不代表变量真实的预测能力。



加V进专属交流群



2.6. WOE和IV的Python代码实现

公众号: Python数据科学



6) Python代码

① Python手动实现公式

```
def feature_woe_iv(x: pd.Series, y: pd.Series, boundary: list, nan: float = -1) -> pd.DataFrame:
    """
    计算变量各个分箱的WOE、IV值，返回一个DataFrame
    """
    x = x.fillna(nan)

    if len(boundary) != 0:
        split = boundary
    else:
        split = optimal_binning_boundary(x, y, nan) # 获得最优分箱边界值列表

    df = pd.concat([x, y], axis=1) # 合并x、y为一个DataFrame，方便后续计算
    df.columns = ['x', 'y'] # 特征变量、目标变量字段的重命名
    df['bins'] = pd.cut(x=x, bins=split, right=False) # 获得每个x值所在的分箱区间

    grouped = df.groupby('bins')['y'] # 统计各分箱区间的好、坏、总客户数量
    result_df = grouped.agg([('good', lambda y: (y == 0).sum()),
                             ('bad', lambda y: (y == 1).sum()),
                             ('total', 'count')])

    result_df['good_pct'] = result_df['good'] / result_df['good'].sum() # 好客户占比
    result_df['bad_pct'] = result_df['bad'] / result_df['bad'].sum() # 坏客户占比
    result_df['total_pct'] = result_df['total'] / result_df['total'].sum() # 总客户占比

    result_df['bad_rate'] = result_df['bad'] / result_df['total'] # 坏比率

    result_df['woe'] = np.log(result_df['bad_pct'] / result_df['good_pct']) # WOE
    result_df['iv'] = (result_df['bad_pct'] - result_df['good_pct']) * result_df['woe'] # IV
    result_df['feature'] = x.name

    iv_value = result_df['iv'].sum()
```

加V进专属交流群



2.6. WOE和IV的Python代码实现

公众号: Python数据科学



6) Python代码

② scorecardpy

```
import scorecardpy as sc
nm = df_1.columns.difference(['ID']).tolist()
sc.iv(df_1[nm], y='target')
```

	variable	info_value
204	certId_dist_ratio	2.880573
2	lmt	2.111058
231	bankCard_last3_edu_encoder	1.880451

scorecardpy官方文档: <https://shichen.name/scorecard/index.html>

③ toad

```
# 输出每个变量的iv值, gini, entropy, 和unique values, 结果以iv值排序
toad.quality(df_1, 'target', iv_only=True)
```

	iv	gini	entropy	unique
dist_last2_loanProduct_count	0.235262	NaN	NaN	112.0
lmt	0.227731	NaN	NaN	1718.0
bankCard_first6_loanProduct_encoder	0.215103	NaN	NaN	279.0
bankCard_last3_loanProduct_count	0.207303	NaN	NaN	255.0

Toad官方文档: https://toad.readthedocs.io/en/stable/tutorial_chinese.html

加V进专属交流群



谢谢

出品人：东哥起飞

解锁风控课程



关注我的公众号



公众号: Python数据科学



加V进专属交流群

